

# Machine Learning sem Perda de Tempo

---

Aumentando as chances de criar produtos que realmente importam

# Eduardo Bonet

@ef\_bonet

Pai, Parceiro, TDAH, mais Lego que juízo

Generalista com orgulho

Senior ML Engineer & Product Lead - MLOps @ GitLab

Essa apresentação é limitada pela minha experiência profissional, e o que apresento é somente uma perspectiva a ser considerada.

A esmagadora  
maioria das  
iniciativas de ML  
morrem no protótipo

# Diversos motivos para isso acontecer

- Líder empolgado com a iniciativa sai da empresa
- Mudança de prioridades da empresa
- Insuficiência de dados ou dados de má qualidade
- Falta de conhecimento das peculiaridades de ML
- Projetos fadados ao fracasso por expectativas inalcançáveis
- Diferentes objetivos entre praticantes de ML, usuários e líderes

# Diversos motivos para isso acontecer

- Líder empolgado com a iniciativa sai da empresa
  - Mudança de prioridades
  - Insuficiência de dados ou dados de má qualidade
- 
- **Falta de conhecimento das peculiaridades de ML**
  - **Projetos fadados ao fracasso por expectativas inalcançáveis**
  - **Diferentes objetivos entre praticantes de ML, usuários e líderes**

# Diversos motivos para isso acontecer

- Líder empolgado com a iniciativa sai da empresa
  - Mudança de prioridades
  - Insuficiência de dados ou dados de má qualidade
- 
- **Falta de conhecimento das peculiaridades de ML**
  - **Projetos fadados ao fracasso por expectativas inalcançáveis**
  - **Diferentes objetivos entre praticantes de ML, usuários e líderes**

**COMUNICAÇÃO**

# Melhorando a Comunicação

Antecipar as perguntas difíceis, para que elas guiem o desenvolvimento do projeto.

Alinhar expectativas com todos envolvidos no projeto.

Não começar projetos fadados a fracassar.

Discussão sobre experiência de usuário deve acontecer no começo do processo, não no final.

É responsabilidade do time de ML explicar para Business como ML funciona

O que é ML?

Machine Learning é um conjunto de algoritmos e **modelos estatísticos** usados para extrair informação de **dados** com um grau de **incerteza**.

Machine Learning é uma ferramenta.



# Quando ML pode ser uma boa alternativa?

Métricas de sucesso bem definidas

Dados de boa qualidade para o problema em questão

A aplicação permite que erros aconteçam

Impacto em escala

# Passo 0: Definindo bem as Sucesso

Qual o objetivo?

Qual o problema que queremos resolver?

Como sabemos se estamos no caminho certo?

Quais os indicadores?

# Passo 0: Definindo bem as Sucesso

Imagine o mundo onde o problema já foi resolvido

# Passo 0: Definindo bem as Sucesso

Imagine o mundo onde o problema já foi resolvido

Nesse mundo, que mudou na experiência no usuário?

# Passo 0: Definindo bem as Sucesso

Imagine o mundo onde o problema já foi resolvido

Nesse mundo, que mudou na experiência no usuário?

Quais os indicadores que podem ser usados para quantificar essas mudanças?

# Passo 0: Definindo bem as Sucesso

Imagine o mundo onde o problema já foi resolvido

Nesse mundo, que mudou na experiência no usuário?

Quais os indicadores que podem ser usados para quantificar essas mudanças?

Qual o indicador de sucesso? Quais são os indicadores de validação?

Toda métrica quando vira um objetivo deixa de ser uma boa métrica

*(Lei de Goodheart)*

Em adição ao indicador de sucesso, é importante ter outros indicadores de validação

# Passo 0: Definindo bem as Sucesso

Seven-steps to set goals and pick metrics for customers



# Como é a experiência do usuário?

A experiência do usuário vai definir quais algoritmos ou não podem ser usados.

- É necessário explicar o porquê cada predição foi feita?
- Em que momento a predição é feita? Quais os dados estão disponíveis no momento da predição?
- Qual o tempo de resposta necessário para uma predição?
- A predição é feita no aparelho do usuário, ou no servidor, ou em um microcontrolador?

....

# Qualidade dos dados?

O modelo de Machine Learning é apenas tão bom quanto os dados disponíveis

- Existe um catálogo de dados?
- Os dados são mantidos, existem alertas para quando algo dá errado?
- Como os dados foram coletados?

# Precisa mesmo de Machine Learning?

Mão de obra escassa e cara

Colocar um modelo em produção requer arquitetura especializada (Model Registry, Pipelines para transformação de dados e treinamento de modelos, monitoramento de predições, etc)

Modelos de Machine Learning tem data de validade: com o tempo as predições vão ficando piores, aumentando o custo de manutenção.

Altamente exploratório, difícil de definir deadlines

Difícil colocar a primeira versão online rápido para iterar com o usuário

# Que tal começar com uma solução sem ML?

Iteração rápida para descobrir o que o usuário realmente quer

Ajuda a coletar dados rapidamente para criar um modelo melhor

Ajuda a definir melhor os indicadores de sucesso e validação

Quando evoluir para uma solução de ML, já existe um baseline

Talvez no final das contas nem precisa evoluir para uma solução de ML

# Consideração: Heurística é Débito técnico

Heurística é solução de curto prazo, e diminui a velocidade de iteração ao longo de tempo.

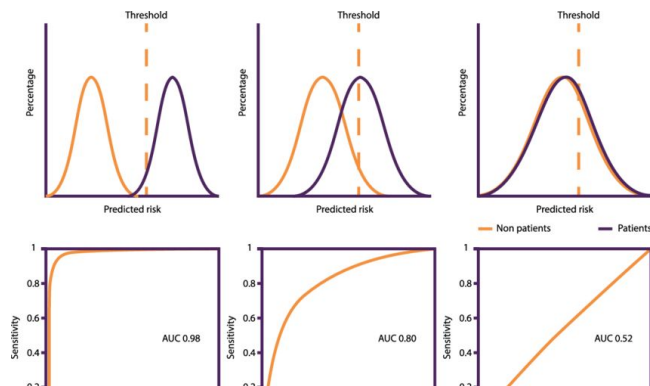
**Métricas acadêmicas\***

nem sempre

são boas

**métricas de negócio**

# Exemplo: AUC para Classificação



[https://www.researchgate.net/figure/Risk-distributions-and-area-under-the-ROC-curve-AUC-adapted-from-Janssens-Martens-35\\_fig4\\_336879307](https://www.researchgate.net/figure/Risk-distributions-and-area-under-the-ROC-curve-AUC-adapted-from-Janssens-Martens-35_fig4_336879307)

AUC traz uma métrica que avalia ao longo de todos os cortes. Na realidade, só um corte vai ser escolhido

# Exemplo: AUC para Classificação

Alternativa: Escolher o retorno onde o ponto de corte traz o máximo retorno

Cada classificação certa ou errada tem um custo associado (em dinheiro, em experiência de usuário)

Qual o corte com melhor custo benefício?

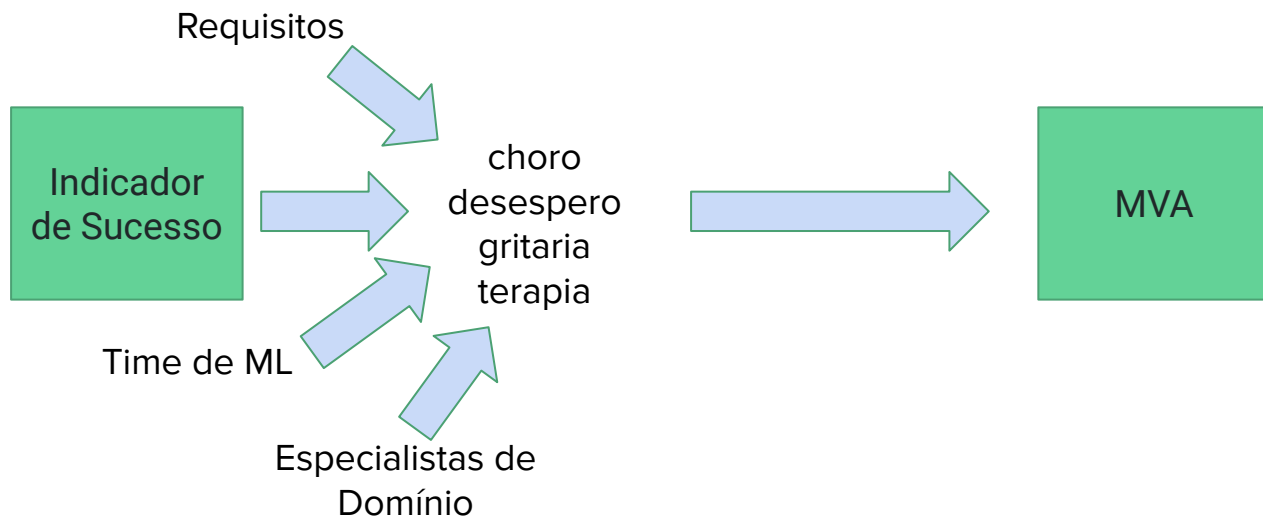
$$\begin{aligned}\text{Retorno}(T) = & \text{Custo\_TP} * \text{TP}(T) \\ & + \text{Custo\_TN} * \text{TN}(T) \\ & - \text{Custo\_FP} * \text{FP}(T) \\ & - \text{Custo\_FN} * \text{FN}(T)\end{aligned}$$



Escolher a métrica  
certa para o modelo  
exige entender o  
problema

# Minimum Viable Accuracy

MVA é o resultado mínimo, em termos de métricas de modelo, que o modelo deve obter para alcançar a definição de sucesso



# Exemplo: Melhorar Ofertas para o usuário

Passo 1: Definição de Sucesso

**Business consideraria o projeto um sucesso se houvesse um aumento de R\$200.000 no retorno mensal**

# Exemplo: Melhorar Ofertas para o usuário

Passo 2: Como é a experiência de usuário?

<b>Como a predição seria acessada?</b>	Usuário acessa a página principal, e vê uma série de itens ofertados.
<b>Existe limite na oferta de itens?</b>	Novos itens são ofertados constantemente
<b>Qual o custo do erro?</b>	Errar uma predição não traz um custo alto

# Exemplo: Sistema de recomendação

Passo 3: Qual a situação atual?

- 5000 usuários mensais
- 10.000 compras
- Compra média de R\$70.00
- Cada usuário vê em média 5 produtos
- 20.000 visitas mensais

# Exemplo: Melhorar Ofertas para o usuário

Passo 4: Que métrica usar?

O que importa aqui é recomendar o produto certo.

Normalmente, usaria-se MAP@K

Número de itens vistos é fixo, então AP@5 faz mais sentido.

# Exemplo: Melhorar Ofertas para o usuário

Passo 5: O que é necessário para chegar no sucesso?

# Exemplo: Melhorar Ofertas para o usuário

Passo 5: O que é necessário para chegar no sucesso?

R\$200.000  $\rightarrow$   $200.000/(70)$   $\rightarrow$  3000 transações adicionais



# Exemplo: Melhorar Ofertas para o usuário

Passo 5: O que é necessário para chegar no sucesso?

R\$200.000  $\rightarrow$   $200.000 / (70) \rightarrow$  3000 transações adicionais

Atualmente 10.000 transações  $\rightarrow$  Aumento de 30% em acertos

# Exemplo: Melhorar Ofertas para o usuário

Passo 5: O que é necessário para chegar no sucesso?

R\$200.000  $\rightarrow$   $200.000/(70)$   $\rightarrow$  3000 transações adicionais

Atualmente 10.000 transações  $\rightarrow$  Aumento de 30% em acertos

AP@5 atual =  $10.000 \text{ transações} / (20.000 \text{ visitas} \times 5 \text{ itens}) = .1$

# Exemplo: Melhorar Ofertas para o usuário

Passo 5: O que é necessário para chegar no sucesso?

R\$200.000  $\rightarrow$   $200.000/(70)$   $\rightarrow$  3000 transações adicionais

Aumento de 30% em acertos

AP@5 atual = 10.000 transações / (20.000 visitas x 5 itens) = .1

AP@5 de sucesso = .1 x 1.3 = 0.13

# MVA: Considerações

É impossível chegar num valor exato para o MVA, basta chegar em um valor aproximado

Normalmente, várias suposições são feitas no cálculo do MVA. Essas suposições devem ser testadas e atualizadas ao longo do tempo

Não se apegue ao valor definido pelo MVA, ele vai mudar com o tempo e conforme ideias vão se cristalizando

# MVA: Considerações

O MVA não é uma ferramenta para educar o business sobre Machine Learning (embora auxilie na definição de expectativas), é uma ferramenta para educar o time de Machine Learning sobre o problema

A maior vantagem de explorar o MVA não é o valor em si, mas os processo de criação. Ao definir o MVA, o time precisa trabalhar com o business para definir as métricas, as expectativas, as peculiaridades do sistema.

# Finalizando

- Antecipar as perguntas difíceis, para que elas guiem o desenvolvimento do projeto.
- Alinhar expectativas com todos envolvidos no projeto.
- Não começar projetos fadados a fracassar.
- Discussão sobre experiência de usuário deve acontecer no começo do processo, não no final.

# Recursos

[Data Science para Negócios](#) [Livro]

[Machine Learning Engineering](#), capítulo 2 [Livro gratuito]

["Everyone wants to do the model work, not the data work": Data Cascades in High-Stakes AI](#) [Artigo]

[150 Successful Machine Learning Models: 6 Lessons Learned at Booking.com](#) [Artigo]

[Seven-steps to set goals and pick metrics for customers](#) [Medium]